FIAP

PROMPT ENGINEERING AND ARTIFICIAL INTELLIGENCE

Subáreas da IA
ML, DL, NLP, IA Generativa, CV e Robótica

Aula 02/18 — Módulo 1: Fundamentos de Inteligência Artificial

👨‍🏫 Prof. Jorge Luiz Gomes

⏱️ Duração: 2h

🐍 Google Colab · Sem API paga

Agenda da Aula

1	Os três paradigmas de Machine Learning	20 min
2	Redes Neurais e Deep Learning — do perceptron às CNNs e RNNs	15 min
3	NLP: do TF-IDF aos Transformers	10 min
4	IA Generativa, Computer Vision e Robótica	10 min
5	Demo Prática: Hugging Face pipelines em 3 linhas de código	30 min
6	Casos Reais + Atividade da Aula	15 min

📚 **REFERÊNCIAS DESTA AULA**

Muller & Guido, Cap. 1–2 · Alpaydin, Cap. 3–5 · Goodfellow et al., Cap. 6, 9–10 · Chollet, Cap. 1

01

Machine Learning

Sistemas que aprendem com dados ao invés de serem programados explicitamente. Os três paradigmas fundamentais.

Os Três Paradigmas de Machine Learning

Machine Learning (ML) é a subárea da IA onde sistemas **aprendem padrões a partir de dados**, sem serem explicitamente programados para cada regra. Existem três abordagens fundamentais (Alpaydin, 2016):

📊

Aprendizado Supervisionado

O modelo aprende com **dados rotulados** — cada entrada tem a resposta correta associada.

Tarefas: Classificação (spam/não-spam), Regressão (preço de imóvel)

Algoritmos: Regressão Linear, Decision Trees, Random Forest, SVM, Redes Neurais

~70% dos projetos de ML

🔍

Aprendizado Não-Supervisionado

O modelo encontra **padrões ocultos** em dados sem rótulos — descobre estrutura por conta própria.

Tarefas: Clustering (segmentação de clientes), Redução de dimensionalidade (PCA)

Algoritmos: K-Means, DBSCAN, PCA, Autoencoders

Descoberta de padrões

🎮

Aprendizado por Reforço

O agente aprende por **tentativa e erro**, recebendo recompensas por boas ações e penalidades por más.

Tarefas: Jogos (xadrez, Go), Robótica, Otimização de rotas

Algoritmos: Q-Learning, PPO, RLHF (usado no ChatGPT!)

Decisões sequenciais

💡 **CONEXÃO COM PROMPT ENGINEERING**

O ChatGPT usa **RLHF (Reinforcement Learning from Human Feedback)** — humanos avaliam respostas, e o modelo aprende a preferir respostas bem avaliadas. Ou sejá, ML supervisionado treina o modelo, e RL refina o comportamento.

02

Deep Learning

Redes neurais com muitas camadas — a revolução que tornou possível tudo o que chamamos de "IA moderna".

A Evolução das Redes Neurais

Deep Learning é ML com **redes neurais de muitas camadas**. Cada camada aprende representações cada vez mais abstratas dos dados (Goodfellow et al., 2017):

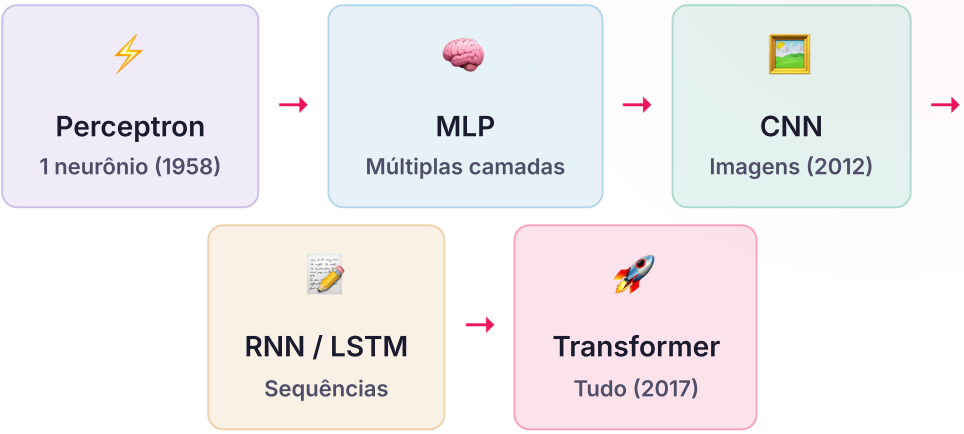

ARQUITETURA	ESPECIALIDADE	COMO FUNCIONA	APLICAÇÃO
MLP	Dados tabulares	Camadas totalmente conectadas, cada neurônio vê todos os inputs	Previsão de preço, classificação
CNN	Imagens	Filtros convolucionais deslizam sobre a imagem detectando padrões	Reconhecimento facial, diagnóstico médico
RNN / LSTM	Sequências	Memória interna que "lembra" dados anteriores na sequência	Tradução (antes), previsão de séries
Transformer	Tudo (texto, imagem, áudio)	Self-attention — cada token "olha" para todos os outros simultaneamente	GPT, Claude, DALL-E, Whisper

🔑 **INSIGHT IMPORTANTE**

O **Transformer** substituiu CNNs e RNNs em quase todas as tarefas. Ele é a base de todos os LLMs modernos. Na Aula 03, vamos dissecar sua arquitetura em detalhe.

NLP: Processamento de Linguagem Natural

NLP é a subárea da IA que permite máquinas **entender, interpretar e gerar línguagem humana**. Passou por uma revolução nos últimos anos:

📜 NLP Clássico (1990–2017)

Bag of Words (BoW) — contar palavras, ignorar ordem

TF-IDF — peso das palavras por frequência e raridade

Word2Vec — primeiros embeddings (representações vetoriais)

Limitações: Sem contexto real, sem compreensão de ambiguidade, necessitava engenharia manual de features

🚀 NLP Moderno (2018–hoje)

BERT (2018) — entende contexto bidirecional

GPT (2018→) — gera texto fluente e coerente

Transformers — attention mechanism resolve a ambiguidade

Resultado: Tradução quase humana, chatbots convincentes, geração de código, sumarização automática

🎯 **ESTA DISCIPLINA VIVE AQUI**

Prompt Engineering é, na essência, **NLP aplicado**. Quando você escreve um prompt, está usando línguagem natural para instruir um modelo de NLP. Dominar os fundamentos de NLP é entender por que certos prompts funcionam e outros não.

Outras Subáreas: IA Generativa, Computer Vision e Robótica

✨

IA Generativa

Cria **conteúdo novo** que não existia nos dados de treino.

Texto: ChatGPT, Claude, Gemini
Imagem: DALL-E 3, Midjourney, Stable Diffusion
Código: GitHub Copilot, Cursor
Áudio: Suno, ElevenLabs
Vídeo: Sora, Runway

Foco desta disciplina

👁️

Computer Vision (CV)

Ensina máquinas a **"enxergar"** e interpretar imagens e vídeos.

Detecção de objetos: YOLO, Detectron2
Segmentação: Segment Anything (SAM)
OCR: ler textos em imagens
Médico: diagnóstico por raio-X

CNNs + Vision Transformers

🤖

Robótica e Controle

IA que controla **agentes físicos** no mundo real.

Drones: navegação autônoma
Carros: Tesla Autopilot, Waymo
Industrial: braços robóticos
RL: principal paradigma de ML usado

Percepção + Decisão + Ação

🔗 **CONVERGÊNCIA: MODELOS MULTIMODAIS**

Em 2026, a fronteira entre essas subáreas está desaparecendo. Modelos como **GPT-4o** e **Gemini** processam texto, imagem e áudio simultaneamente. Na Aula 17, vamos explorar multimodalidade em detalhe.

Mapa Completo: Subáreas da IA e Suas Conexões

Quando alguém disser "IA", pergunte: **qual subárea?** Cada produto de IA usa uma combinação delas:

PRODUTO / FERRAMENTA	SUBÁREAS ENVOLVIDAS	PARADIGMA DE ML	ARQUITETURA
ChatGPT	NLP + IA Generativa	Supervisionado + RLHF	Transformer (decoder-only)
GitHub Copilot	NLP + IA Generativa + Code	Supervisionado + RLHF	Transformer
Midjourney	CV + IA Generativa	Supervisionado	Diffusion Model
Tesla Autopilot	CV + Robótica	Supervisionado + Reforço	CNN + Transformer
Netflix Recomendação	ML clássico	Supervisionado + Não-supervisionado	Embeddings + Filtragem colaborativa
Nubank Fraude	ML clássico + NLP	Supervisionado	Gradient Boosting + NLP
AlphaFold	Bioinformática	Supervisionado	Transformer + CNN

03

Demo Prática

Hugging Face pipelines — NLP, Computer Vision e Geração de Texto em 3 linhas de Python cada.

Pipeline 1: Análise de Sentimento (NLP)

O Hugging Face oferece **pipelines pré-treinados** que encapsulam todo o processo em uma única chamada:

01_sentiment_analysis.py · Google Colab

```python
# 📦 Instalar a biblioteca transformers do Hugging Face
!pip install transformers -q

# 📚 Importar o pipeline pronto
from transformers import pipeline

# 🎉 Criar o classificador de sentimento
classificador = pipeline("sentiment-analysis")

# 💬 Testar com frases em inglês
frases = [
    "I love studying Artificial Intelligence!",
    "This homework is terrible and boring.",
    "The weather today is okay, nothing special.",
]

# 🔍 Classificar cada frase
resultados = classificador(frases)

# 🖨️ Mostrar resultados
for frase, res in zip(frases, resultados):
    print(f"'{frase[:40]}...' → {res['label']} ({res['score']:.2%})")
```

✅ **OUTPUT ESPERADO**

```
'I love studying Artificial Intelligence...' → POSITIVE (99.87%)
'This homework is terrible and boring...' → NEGATIVE (99.93%)
'The weather today is okay, nothing spec...' → POSITIVE (63.21%)
```

Pipeline 2: Classificação de Imagens (Computer Vision)

02_image_classification.py · Google Colab

```python
from transformers import pipeline

# 🖼️ Criar classificador de imagens
classificador_img = pipeline("image-classification")

# 📸 Classificar uma imagem da web (URL direta para um JPG)
url =
"https://upload.wikimedia.org/wikipedia/commons/thumb/4/4d/Cat_November_2010-
1a.jpg/1200px-Cat_November_2010-1a.jpg"

resultado = classificador_img(url)

# 🏷️ Mostrar top-3 classificações
print("🖼️ Classificações da imagem:")
for r in resultado[:3]:
    print(f"  {r['label']:30s} → {r['score']:.2%}")
```

O que aconteceu? O pipeline baixou um modelo **ViT (Vision Transformer)** pré-treinado no ImageNet, processou a imagem e retornou as categorias mais prováveis. Nenhum treinamento necessário — isso é **transfer learning** em ação.

Pipeline 3: Geração de Texto (IA Generativa)

03_text_generation.py · Google Colab

```python
from transformers import pipeline

# ✍️ Criar gerador de texto
gerador = pipeline("text-generation", model="gpt2")

# 💬 Gerar continuação a partir de um prompt
prompts = [
    "The future of artificial intelligence is",
    "Python is the best programming language because",
]

for prompt in prompts:
    resultado = gerador(prompt, max_new_tokens=50, do_sample=True)
    print(f"\n🔷 Prompt: '{prompt}'")
    print(f"   Gerado: {resultado[0]['generated_text'][:200]}")
```

💡 **OBSERVE**

O GPT-2 é um modelo de 2019 com 124M de parâmetros — **1.400 vezes menor** que o GPT-4. Mesmo assim, já gera texto coerente. Execute várias vezes e veja: **cada execução gera um texto diferente** (por causa do `do_sample=True`). Esse é o conceito de *temperatura* que vamos aprofundar na Aula 03.

Bônus: ML Clássico com scikit-learn (Classificação)

Para contrastar com Deep Learning, vejá como ML clássico funciona — treinar um classificador do zero com dados reais:

04_sklearn_iris.py · Google Colab

```python
# 📊 ML Clássico — classificação com scikit-learn
from sklearn.datasets import load_iris
from sklearn.model_selection import train_test_split
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import accuracy_score

# 🌸 Carregar dataset Iris (150 amostras, 3 espécies de flor)
iris = load_iris()
X_treino, X_teste, y_treino, y_teste = train_test_split(
    iris.data, iris.target, test_size=0.3, random_state=42
)

# 🌲 Treinar um Random Forest (conjunto de árvores de decisão)
modelo = RandomForestClassifier(n_estimators=100, random_state=42)
modelo.fit(X_treino, y_treino)

# 📏 Avaliar no conjunto de teste
previsoes = modelo.predict(X_teste)
acuracia = accuracy_score(y_teste, previsoes)

print(f"🎯 Acurácia: {acuracia:.1%}")
print(f"🌸 Espécies: {list(iris.target_names)}")
```

🔑 **COMPARAÇÃO ML CLÁSSICO VS DEEP LEARNING**

ML Clássico (sklearn): Você prepara dados, escolhe algoritmo, treina, avalia. Precisa de dados rotulados e feature engineering.

Deep Learning (pipeline HF): Modelo pré-treinado já "sabe" a tarefa. Você só passa o input. Isso é o poder do **transfer learning**.

Casos Reais: Subáreas da IA em Produção

🇧🇷 NUBANK

Detecção de fraude com ML supervisionado

O Nubank processa milhões de transações por dia usando modelos de ML para identificar fraudes em tempo real. Utiliza Gradient Boosting + features comportamentais — ML clássico ainda dominante em fintechs por latência e interpretabilidade.

🇧🇷 IFOOD

Previsão de demanda e recomendação

O iFood usa ML para prever demanda por restaurante/região/horário e otimizar a logística de entregadores. O sistema de recomendação combina filtragem colaborativa (não-supervisionado) com predição de preferência (supervisionado).

🇧🇷 DATAPREV

NLP para processamento de benefícios

A Dataprev utiliza NLP para processar e classificar automaticamente requerimentos de benefícios sociais, extraindo informações de textos não-estruturados submetidos por cidadãos — aplicação direta de extração de entidades e classificação de texto.

🇧🇷 JUREMA.AI

IA Generativa para o direito

Startup brasileira que usa LLMs para analisar processos jurídicos, gerar petições e resumir documentos legais. Combina NLP + IA Generativa + RAG para lidar com o volume massivo de documentos do judiciário brasileiro.

Atividade da Aula

✏️

EXERCÍCIO PRÁTICO — EM DUPLA ⭐⭐☆

"Qual subárea está por trás?" + Experimentação com Pipelines

Parte 1 — Identificação de Subáreas (10 min)

1. Para cada produto abaixo, identifique: **qual(is) subárea(s) da IA** ele usa, **qual paradigma de ML** e **qual arquitetura provável**:
   → **Google Translate · Shazam · Waze · Spotify Discover Weekly · DeepL**
2. Discuta com sua dupla e anotem as respostas

Parte 2 — Experimentação no Colab (15 min)

1. Execute os 3 pipelines desta aula no Google Colab
2. Modifique o pipeline de **sentimento**: teste com frases em português. Funciona bem? Por quê?
3. Modifique o pipeline de **geração de texto**: troque o prompt para algo sobre sua área de interesse
4. **Desafio bônus** ⭐⭐⭐ **:** Descubra no Hugging Face Hub um pipeline para **tradução** (`translation`) e faça funcionar com português → inglês

💡 **Dica:** O Hugging Face Hub tem modelos multilíngues. Para sentimento em PT-BR, procure por modelos com "multilíngual" ou "portuguese" no nome. Tente: `nlptown/bert-base-multilíngual-uncased-sentiment`

Referências e Leitura Complementar

LIVRO **MULLER, A.C.; GUIDO, S.** Introdução ao Aprendizado de Máquina com Python. Pearson, 2016. Cap. 1–2.

LIVRO **ALPAYDIN, E.** Aprendizado de Máquina. Pearson, 2016. Cap. 3–5.

LIVRO **GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A.** Deep Learning. Pearson, 2017. Cap. 6, 9–10.

LIVRO **CHOLLET, F.** Deep Learning com Python. Pearson, 2018. Cap. 1.

ONLINE **Hugging Face** — Pipeline Tutorial

ONLINE **scikit-learn** — scikit-learn.org/stable/tutorial

FIAP

Resumo da Aula 02

- ✅ ML tem 3 paradigmas: supervisionado, não-supervisionado e reforço
- ✅ Deep Learning = redes neurais profundas. Transformer é a arquitetura dominante
- ✅ NLP evoluiu de TF-IDF para Transformers — base de tudo em Prompt Engineering
- ✅ IA Generativa cria conteúdo novo: texto, imagem, código, áudio e vídeo
- ✅ Hugging Face pipelines: NLP, CV e geração em 3 linhas de Python

→ PRÓXIMA AULA — AULA 03

Como Funcionam os LLMs — Tokens, Embeddings e Arquitetura Transformer

Vamos abrir o capô dos LLMs: tokenização, espaço vetorial e o mecanismo de attention.

Copyright © 2026 Prof. Jorge Luiz Gomes · FIAP · Todos os direitos reservados.