FIAP

PROMPT ENGINEERING AND ARTIFICIAL INTELLIGENCE

Ambiente Python para IA Colab, Hugging Face, Ollama e APIs Gratuitas

Aula 04/18 — Módulo 1: Fundamentos de Inteligência Artificial

👨‍🏫 Prof. Jorge Luiz Gomes

⏱️ Duração: 2h

🧪 AULA LAB — 70% prática

🐍 Google Colab · Sem API paga

Agenda da Aula

1	Visão geral: o ecossistema Python para IA em 2026	10 min
2	Google Colab: setup, GPU grátis, dicas de produtividade	15 min
3	Hugging Face Hub + Inference API (free tier)	15 min
4	Ollama: rodando LLMs localmente	15 min
5	Lab Prático: Mini-Chatbot em 20 linhas de Python	30 min
6	Casos Reais + Entrega do Módulo 1	15 min

📚 **REFERÊNCIAS DESTA AULA**

Muller & Guido, Cap. 1 · Chollet, Cap. 1 · Documentação oficial: Google Colab, Hugging Face, Ollama

O Ecossistema Python para IA em 2026

O fluxo completo de uma aplicação com IA:

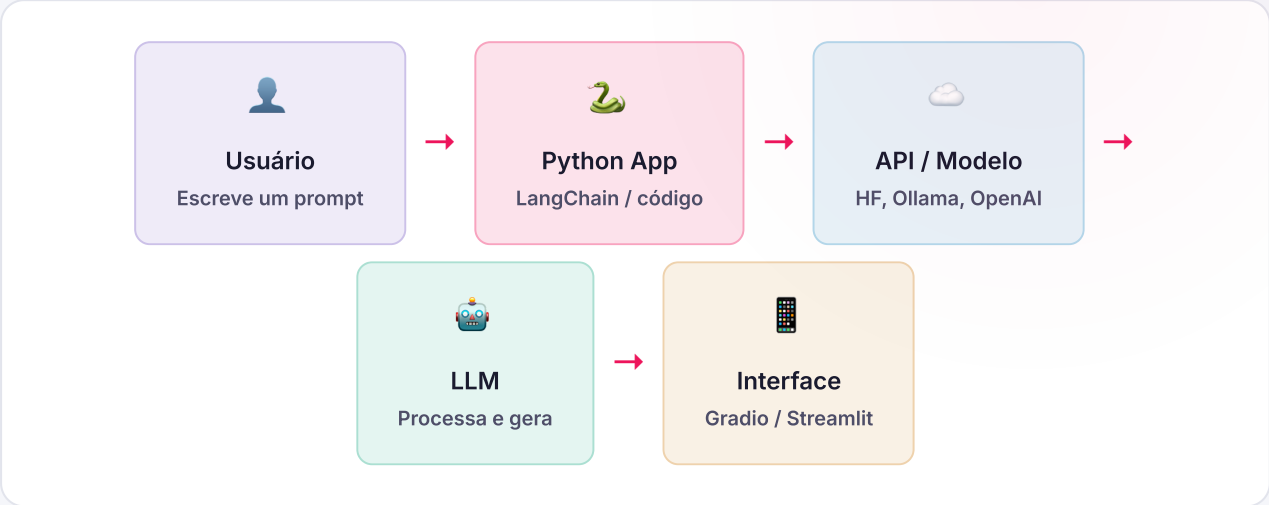

CAMADA	FERRAMENTA	FUNÇÃO	CUSTO
Ambiente	Google Colab	Notebook Python na nuvem com GPU	✅ Gratuito (T4 GPU)
Modelos (nuvem)	Hugging Face Inference API	Centenas de modelos via API REST	✅ Free tier (rate limited)
Modelos (local)	Ollama	Rodar LLaMA, Mistral etc. na sua máquina	✅ 100% gratuito
Framework	LangChain	Chains, prompts, memória, RAG	✅ Open-source
Embeddings	Sentence Transformers	Gerar vetores semânticos	✅ Open-source
Vector Store	ChromaDB / FAISS	Busca semântica em documentos	✅ Open-source
Interface	Gradio / Streamlit	UI web para demos e apps	✅ Open-source

01

Google Colab

Seu laboratório na nuvem — Python + GPU grátis, sem instalar nada. Abra o navegador e comece.

Google Colab: Setup e Dicas Essenciais

🚀

Como começar

1. Acesse colab.research.google.com
2. Faça login com conta Google
3. **Novo Notebook** → pronto!
4. Para GPU: **Runtime → Change runtime type → T4 GPU**
5. Notebooks salvam automaticamente no Google Drive

⚡

Dicas de produtividade

Ctrl+Enter — executar célula atual
Shift+Enter — executar e ir para próxima
!comando — executar terminal (ex: `!pip install`)
%time — medir tempo de execução
Tab — autocomplete
?função — ver documentação

00_setup_ambiente.py · Google Colab

```python
# 📦 Instalar TODAS as bibliotecas que usaremos no curso
!pip install -q \
    transformers \
    huggingface_hub \
    sentence-transformers \
    langchain \
    langchain-community \
    chromadb \
    gradio \
    tiktoken

# ✅ Verificar se tudo instalou corretamente
import transformers, huggingface_hub, sentence_transformers
import langchain, chromadb, gradio, tiktoken

print("✅ Todas as bibliotecas instaladas com sucesso!")
print(f"🤗 transformers: {transformers.__version__}")
print(f"🔗 langchain: {langchain.__version__}")
```

02

Hugging Face

O "GitHub dos modelos de IA" — 500K+ modelos, datasets e uma Inference API gratuita.

Hugging Face: Modelos e Inference API

O que é o Hugging Face Hub?

Repositório com **500K+ modelos** de IA open-source. Qualquer pessoa pode publicar e baixar modelos. Para cada modelo, há card com benchmark, código de uso e demo.

Inference API: Roda modelos na nuvem do HF sem precisar baixar nada. Free tier permite ~30K tokens/dia — suficiente para experimentação.

Modelos que usaremos no curso

Texto: Zephyr-7B, Phi-3, Gemma-2
Embeddings: all-MiniLM-L6-v2
Classificação: distilbert-base-uncased
Tradução: Helsinki-NLP/opus-mt
Imagem: google/vit-base-patch16

Todos 100% gratuitos.

01_huggingface_api.py · Google Colab

```python
from huggingface_hub import InferenceClient

# 🔗 Criar cliente (sem chave — free tier público)
client = InferenceClient()

# 💬 Chat com um modelo de conversação
mensagens = [
    {"role": "user", "content": "O que é Prompt Engineering? Responda em 2 frases."}
]

resposta = client.chat_completion(
    mensagens,
    model="HuggingFaceH4/zephyr-7b-beta",
    max_tokens=150
)

print(resposta.choices[0].message.content)
```

03

Ollama

Rode LLaMA, Mistral e outros modelos diretamente no seu computador — sem internet, sem API, sem custo.

Ollama: LLMs Rodando Localmente

Ollama (ollama.com) permite rodar modelos de IA no seu computador. Sem internet, sem limites de API, sem custo. Ideal para experimentação e privacidade.

Terminal — Instalar e rodar Ollama · Google Colab

```
# 📦 Instalar Ollama (Linux/Mac)
curl -fsSL https://ollama.com/install.sh | sh

# 🦙 Baixar e rodar LLaMA 3.2 (3B parâmetros — roda em qualquer notebook)
ollama run llama3.2

# 🔷 Outros modelos recomendados:
ollama run mistral        # Mistral 7B — europeu, compacto
ollama run phi3           # Phi-3 — Microsoft, otimizado
ollama run gemma2:2b      # Gemma 2 — Google, 2B params
```

02_ollama_python.py · Terminal local ou Colab · Google Colab

```python
import requests

# 💬 Chamar Ollama via API local (porta 11434)
resposta = requests.post(
    "http://localhost:11434/api/generate",
    json={
        "model": "llama3.2",
        "prompt": "O que é Inteligência Artificial? Responda em português.",
        "stream": False
    }
)

print(resposta.json()["response"])
```

📌 **QUANDO USAR CADA OPÇÃO?**

Google Colab + HF API: Aulas, exercícios, prototipação rápida. Funciona em qualquer computador com navegador.

Ollama: Projeto final, experimentação livre sem limites, privacidade de dados. Precisa de 8GB+ RAM.

04

Lab Prático

Construa seu primeiro chatbot funcional em 20 linhas de Python — com histórico de conversa!

Mini-Chatbot em 20 Linhas de Python

03_mini_chatbot.py · Google Colab

```python
from huggingface_hub import InferenceClient

client = InferenceClient()

# 📝 Histórico de conversa (memória simples)
histórico = [
    {"role": "system", "content": "Você é um assistente prestativo. Responda
sempre em português."}
]

print("🤖 Mini-Chatbot FIAP (digite 'sair' para encerrar)")
print("=" * 50)

while True:
    msg = input("\nVocê: ")
    if msg.lower() == "sair":
        print("👋 Até a próxima aula!")
        break

    histórico.append({"role": "user", "content": msg})

    resp = client.chat_completion(
        histórico, model="HuggingFaceH4/zephyr-7b-beta", max_tokens=200
    )

    resposta = resp.choices[0].message.content
    print(f"🤖 Bot: {resposta}")
    histórico.append({"role": "assistant", "content": resposta})
```

🔑 **O QUE ESSE CÓDIGO ENSINA?**

System prompt: Define a persona do bot (linha 5). **Histórico:** A lista `histórico` mantém todas as mensagens — é assim que o bot "lembra" o contexto. **Roles:** system, user, assistant — os 3 papéis fundamentais de toda API de chat. Tudo isso será aprofundado nos Módulos 2 e 4.

Casos Reais: Ecossistema Open-Source no Brasil

🇧🇷 PIPEFY

Automação de processos com IA open-source

A Pipefy integrou LLMs open-source para automatizar processos de RH e compras, usando LangChain + modelos via API. Reduziu tempo de triagem de candidatos em 60%. Stack: Python + LangChain + Hugging Face models + PostgreSQL.

🇧🇷 NEOWAY

Big data + NLP para inteligência de mercado

Startup brasileira de big data que usa NLP para extrair informações de documentos públicos, analisar risco de empresas e gerar insights de mercado. Combina modelos open-source com pipeline Python + ChromaDB para busca semântica.

🌍 HUGGING FACE

De startup a plataforma central da IA

Avaliada em US$ 4.5 bilhões, o HF se tornou infraestrutura essencial. 500K+ modelos hospedados, Inference API gratuita, Spaces para deploy de demos. Toda a comunidade open-source de IA gira em torno do Hub.

🌍 OLLAMA

Democratizando LLMs locais

Ollama permite que qualquer pessoa rode modelos como LLaMA, Mistral e Phi no próprio computador. Mais de 1M de downloads. Usado por desenvolvedores que precisam de privacidade de dados ou acesso offline.

Atividade da Aula

🧪

LAB PRÁTICO — INDIVIDUAL ⭐⭐☆

"Meu Primeiro Chatbot Personalizado"

1. Execute o código do **setup de ambiente** (Slide 05) e verifique que todas as bibliotecas instalaram
2. Execute o código do **mini-chatbot** (Slide 11) e converse com ele por 3-4 turnos
3. **Modifique o system prompt** para criar uma personalidade diferente:
   → Ex: *"Você é um chef de cozinha brasileiro que responde tudo usando metáforas culinárias"*
   → Ex: *"Você é um professor de história que explica tudo com analogias de videogames"*
4. Teste: o bot mantém a personalidade ao longo da conversa?
5. **Desafio bônus** ⭐⭐⭐ **:** Adicione um contador de tokens no chatbot — mostre quantos tokens cada mensagem usa (dica: use tiktoken)

💡 **Dica:** Se o free tier do HF retornar erro 429 (rate limit), espere 1 minuto. Alternativa: troque o modelo para `microsoft/Phi-3-mini-4k-instruct` ou `google/gemma-2-2b-it`.

📋

ENTREGA DO MÓDULO 1 — PRAZO: AULA 05

Relatório Individual — "Mapa Mental da IA Generativa"

Escolha **3 ferramentas de IA** (ex: ChatGPT, GitHub Copilot, Midjourney, Suno, Perplexity). Para cada uma, identifique: qual **subárea da IA** ela usa (NLP, CV, IA Generativa etc.), qual **arquitetura provável** (Transformer decoder-only, diffusion model etc.), o **impacto no mercado de trabalho**, e faça um **teste prático** (use a ferramenta e documente o resultado).

Formato: documento + mapa mental visual (pode ser Miro, Canva, draw.io ou papel escaneado). **Peso: 10% da nota final.**

Referências e Leitura Complementar

LIVRO **MULLER, A.C.; GUIDO, S.** Introdução ao Aprendizado de Máquina com Python. Pearson, 2016. Cap. 1 (Setup do ambiente).

LIVRO **CHOLLET, F.** Deep Learning com Python. Pearson, 2018. Cap. 1 (Ecossistema Python para DL).

ONLINE **Google Colab** — colab.research.google.com

ONLINE **Hugging Face** — huggingface.co/docs — Documentação completa + Inference API

ONLINE **Ollama** — ollama.com — Documentação + lista de modelos disponíveis

ONLINE **LangChain** — python.langchain.com — Framework para aplicações com LLMs

FIAP

Resumo da Aula 04 — Fim do Módulo 1!

- ✅ Google Colab: ambiente Python + GPU grátis, funciona no navegador
- ✅ Hugging Face: 500K+ modelos + Inference API gratuita
- ✅ Ollama: LLMs rodando localmente, sem internet, sem custo
- ✅ Mini-chatbot em 20 linhas: system prompt, histórico, roles
- ✅ Todas as ferramentas do curso são 100% gratuitas
- 📋 **Entrega M1:** Mapa Mental da IA Generativa (prazo: Aula 05)

→ PRÓXIMA AULA — AULA 05 · INÍCIO DO MÓDULO 2

Prompt Engineering — Conceito, Anatomia, Boas Práticas e Anti-padrões

Finalmente entramos no core da disciplina: como se comunicar efetivamente com LLMs!

Copyright © 2026 Prof. Jorge Luiz Gomes · FIAP · Todos os direitos reservados.